

徐炯炀

电话：15713891082 | 邮箱：xuty1218@163.com | Google Scholar
研究方向：AI for SE、LLM Agents、Software Security | 外语水平：CET-6（487）

教育背景

东南大学（985、211、双一流） 网络空间安全学院 2024.09 – 2027.06
网络与信息安全 硕士研究生 导师：嘉炬 副教授

东北林业大学（211、双一流） 计算机与控制工程学院 2020.09 – 2024.06
数据科学与大数据技术 理学学士 专业排名 2/41，推免至东南大学

荣誉奖项：黑龙江省三好学生、东南大学三好研究生、东南大学优秀共青团员、本科优秀毕业生、中国大学生计算机设计大赛国家二等奖、全国大学生数学建模竞赛省一等奖、美国大学生数学建模竞赛 H 奖等**十余项**荣誉与竞赛奖项

学术论文

[1] **T. Xu**, J. Li, J. Xiong, J. Jia*, Y. Wu, S. Ma, G. Cheng, and R. H. Deng. AttaCode: Attribution-Guided Adversarial Code Generation via Jailbreak-Enabled Prompts against Vulnerability Detection Models. *IEEE Transactions on Dependable and Secure Computing (TDSC)*, 2026. [DOI] （第一作者，CCF-A）

[2] C. Li†, **T. Xu**†, S. Dou, J. Li, J. Jia*, Y. Wu, and D. Zou. Building Global Sample Graph for Effective Code Clone Detection. *Journal of Systems and Software (JSS)*, 2026. [DOI] （共同一作，CCF-B，JCR Q1）

科研项目

基于人工智能的标准漏洞数据集构建及智能化漏洞检测技术研究 2024.12 – 2026.12
浙江大学区块链与数据安全全国重点实验室开放课题（A2419）。作为项目参与人，围绕课题中的智能化漏洞检测任务，负责检测模型的对抗鲁棒性评估与增强研究，以第一作者发表 TDSC（CCF-A）论文 1 篇。

科研经历

面向软件脆弱性检测模型的对抗代码生成研究 [1] 2025.03 – 2026.01

- 针对现有代码对抗攻击变换空间狭窄、缺乏细粒度扰动指导，以及为绕过 LLM 安全对齐而切分代码、破坏漏洞语义依赖的问题，提出归因引导的对抗代码生成方法 AttaCode，在完整程序上下文中实现越狱提示驱动的对抗生成。
- 设计“细粒度重要性分析—越狱提示优化—迭代对抗生成”三阶段框架：以单次反向传播的梯度归因估计 token 重要性并聚合至 AST 节点，据此为 25 种语义保持变换排序；采用“优化器—生成器”双 LLM，依据拒绝反馈迭代变异带代码/规则占位符的越狱提示；生成阶段将完整源码与动态选取的规则填入占位符，迭代生成对抗样本。
- 在 Devign、BigVul、DiverseVul 上攻击 CodeBERT、UniXcoder、CodeT5，并与 7 种 SOTA 方法对比：平均攻击成功率超过 80%，检测器查询减少 75%–96%，在 RanMASK 防御下检出率最低；HumanEval-X 上连续三次变换后 89.9% 的程序仍通过测试；对抗微调使检测准确率提升 9.56–12.52 个百分点。

基于全局样本图的大规模代码克隆检测研究 [2] 2024.08 – 2025.01

- 针对现有克隆检测方法孤立表示单个代码样本、忽略样本间全局关联，且树/图结构方法难以扩展至大规模代码库的问题，研究基于全局样本图的克隆检测方法 Gitor，将样本间共享的词法与结构信息显式建模为全局关联。
- 引入 27 项代码度量（分 8 组系统评估），与关键词分别构建加权二部图并融合为全局样本图，经 ProNE 嵌入得到样本向量；在余弦相似度快速检测之外，设计神经网络分类器（Gitor-1L/2L/3L）识别复杂语义克隆。
- 在 BigCloneBench 上与 10 种传统检测器、7 种深度学习方法及 2 种 LLM 对比，Gitor-2L/3L 的 F1 均达 0.99，较先进深度学习方法提升 4%–17%，Gitor-2L 在 GoogleCodeJam 上 F1 达 0.95；基于余弦相似度的 Gitor 仅需 11 秒完成百万级代码对检测，较 ASTNN 运行时间减少 95% 以上。

实习经历

北京快手科技有限公司·数据平台部 Agent 研发实习生 2026.06 – 2026.09
简介：参与快手内部自助取数与数据分析 Data Agent 核心机制设计，聚焦查询生成可靠性、长程上下文与运行容错。

- 针对 LLM 直接生成 SQL 易出现字段幻觉的问题，设计“自然语言 → 受限中间表示 → 平台 DSL”两阶段链路，语义理解交由模型、语法与执行交由确定性编译器，并将字段幻觉转为结构化反馈驱动重试，形成生成—校验—纠错闭环。
- 针对多轮 ReAct 中工具结果堆积导致上下文超限、长链路任务中断的问题，将上下文释放建模为显式收益权衡：按“可释放量 × (1 − 语义损失)”在工具结果卸载与历史摘要压缩间择优，并以模型返回的真实 token 用量触发释放。
- 针对模型失败类型混杂、工具调用陷入无效循环的问题，设计错误类型驱动的分级容错（退避重试、会话内粘性降级、快速终止），并在签名精确匹配之上引入轻量模型语义判定，识别参数不同但意图重复的隐性循环并安全终止。

之江实验室·科学数据枢纽研究中心 大模型算法实习生 2026.03 – 2026.05
简介：面向科学语料知识点自动标注，构建基于知识树逐层决策的轻量模型微调方案，降低教师大模型批量标注开销。

- 针对知识路径层级较深、候选节点相似度高的问题，将层级路径预测重构为“给定父路径的逐层候选排序与终止判断”；经质量筛选与去重构造 59,752 条 SFT 样本，并以教师排除节点和同层兄弟节点作为困难负例。
- 基于 LLaMA-Factory 对 Qwen3-1.7B 进行 LoRA SFT，在 IID、跨来源与困难样本三类场景下评测：逐层 Top-1 准确率在 IID 集上由 63.7% 提升至 89.6%，跨来源与困难集分别提升 23.9 和 17.7 个百分点。